



Réalisez un traitement dans un environnement Big Data sur le Cloud

Projet 11 - Julien Agneray

Présentation du projet "Fruits!"






Sommaire

1. Jeu de données
2. Notions de Big Data et infrastructure cloud
3. Sécurité et configuration de l'environnement
4. Traitement distribué avec EMR
5. Transfert Learning et chaîne de traitement PySpark
6. Démonstration
7. Conclusion


Jeu de données

Gestion efficace des données pour la classification d'images de fruits



Qu'est-ce que le Big Data ?

Caractéristiques du Big Data



Stockage des données avec Amazon S3



Configuration IAM et accès CLI

p11-user [Infos](#) [Supprimer](#)

Récapitulatif

ARN  <code>arn:aws:iam::808238800744:user/p11-user</code>	Accès par console Désactivé	Clé d'accès 1 Créer une clé d'accès
Création March 22, 2025, 16:05 (UTC+01:00)	Dernière connexion à la console -	

Autorisations | Groupes | Balises | Informations d'identification de sécurité | Dernier accès

Politiques des autorisations (1)

Les autorisations sont définies par des politiques attachées à l'utilisateur directement ou via des groupes.

Filtrer par Type

Rechercher

Tous les types

< 1 > ⚙

Nom de la politique	Type	Attaché via
 AmazonS3FullAccess	Gérées par AWS	Directement

```
$ aws configure
```

```
AWS Access Key ID [None]: AKIA*****
```

```
AWS Secret Access Key [None]: wJa1rXUtnFEMI/K7MDENG/bPxRfiCY*****
```

```
Default region name [None]: eu-west-3
```

```
Default output format [None]: json
```

Accès SSH et configuration du groupe de sécurité

Modifier les règles entrantes [Informations](#)

Les règles entrantes contrôlent le trafic entrant qui est autorisé à atteindre l'instance.

Règles entrantes [Informations](#)

ID de règle de groupe de sécurité	Type Informations	Protocole Informations	Plage de ports Informations	Source Informations	Description - facultatif Informations	
sgr-0e198897e5937d7fd	Tous les UDP	UDP	0 - 65535	Personn... Q		Supprimer
				sg-0437aca3078b98d5c X		
sgr-09310bf710490eafa	Tous les TCP	TCP	0 - 65535	Personn... Q		Supprimer
				sg-0437aca3078b98d5c X		
sgr-0748544d40f02a80a	Tous les TCP	TCP	0 - 65535	Personn... Q		Supprimer
				sg-0212f43f0fd0b18ba X		
sgr-03204fea786356703	Tous les ICMP - IPv4	ICMP	Tous	Personn... Q		Supprimer
				sg-0212f43f0fd0b18ba X		
sgr-068415a62403f1d35	TCP personnalisé	TCP	8443	Personn... Q		Supprimer
				pl-4aa04523 X		
sgr-0dfe610f97b5668b1	Tous les UDP	UDP	0 - 65535	Personn... Q		Supprimer
				sg-0212f43f0fd0b18ba X		
sgr-0b164fdfaf663dc24	Tous les ICMP - IPv4	ICMP	Tous	Personn... Q		Supprimer
				sg-0437aca3078b98d5c X		
-	SSH	TCP	22	N'impor... Q		Supprimer
				0.0.0.0/0 X		

Amazon EMR : Environnement logiciel

Créer un cluster [Info](#)

▼ Nom et applications - *requis* [Info](#)

Donnez un nom à votre cluster et choisissez les applications que vous voulez y installer.

Nom

P11-Cluster

Version Amazon EMR [Info](#)

Une version contient un ensemble d'applications susceptibles d'être installées sur votre cluster.

emr-6.13.0

Offre d'applications

Spark

Core Hadoop

Flink

HBase

Presto

Trino

Custom

- | | | |
|---|---|---|
| ☐ Flink 1.17.0 | ☐ Ganglia 3.7.2 | ☐ HBase 2.4.17 |
| ☐ HCatalog 3.1.3 | ☒ Hadoop 3.3.3 | ☐ Hive 3.1.3 |
| ☐ Hue 4.11.0 | ☐ JupyterEnterpriseGateway 2.6.0 | ☒ JupyterHub 1.5.0 |
| ☐ Livy 0.7.1 | ☐ MXNet 1.9.1 | ☐ Oozie 5.2.1 |
| ☐ Phoenix 5.1.3 | ☐ Pig 0.17.0 | ☐ Presto 0.281 |
| ☒ Spark 3.4.1 | ☐ Sqoop 1.4.7 | ☒ TensorFlow 2.11.0 |
| ☐ Tez 0.10.2 | ☐ Trino 414 | ☒ Zeppelin 0.10.1 |
| ☐ ZooKeeper 3.5.10 | | |

Paramètres du catalogue de données AWS Glue

Utilisez le catalogue de données AWS Glue pour fournir un metastore externe à votre application.

- ☐ Utiliser pour les métadonnées de table Spark

Options du système d'exploitation [Info](#)

- ☒ Version Amazon Linux :
- ☐ Amazon Machine Image (AMI) personnalisée
- ☒ Appliquez automatiquement les dernières mises à jour Amazon Linux

Récapitulatif [Info](#)

Nom et applications - *requis*

Nom

P11-Cluster

Version Amazon EMR

emr-6.13.0

Offre d'applications

Custom (Hadoop 3.3.3, JupyterHub 1.5.0, Spark 3.4.1, TensorFlow 2.11.0, Zeppelin 0.10.1)

Configuration de cluster - *requis*

Groupe d'instances uniformes

Primaire (m5.xlarge), Unité principale (m5.xlarge),
Tâche (m5.xlarge)

Dimensionnement et mise en service du cluster - *requis*

Configuration de mise en service

Taille du noyau: 1 instance
Taille de la tâche: 1 instance

❗ Configuration des rôles IAM

Vous devez choisir une fonction du service et un profil d'instance avant de créer ce cluster.

Choisir un rôle IAM

Annuler

Créer un cluster

Calcul distribué dans le cloud avec EMR

▼ Configuration de cluster - *requis* [Info](#)

Choisissez une méthode de configuration pour les groupes de nœuds primaires, principaux et de tâches de votre cluster.

☒ Groupes d'instances uniformes

Choisissez le même type d'instance EC2 et la même option d'achat (à la demande ou Spot) pour tous les nœuds de votre groupe de nœuds. [En savoir plus](#)

☐ Flottes d'instances flexibles

Choisissez parmi la plus grande variété d'options de provisionnement pour les instances EC2 de votre cluster. Diversifiez les types d'instances et les options d'achat, et utilisez une stratégie d'allocation. [En savoir plus](#)

Groupes d'instances uniformes

Primaire

Choisir un type d'instance EC2

m5.xlarge

4 vCore 16 GiB mémoire

EBS uniquement stockage

Prix à la demande : 0.224 USD par insta...

Prix Spot le plus bas : 0.078 USD (eu-west...

Actions ▼

☐ Utiliser la haute disponibilité

Lancez des clusters hautement disponibles et plus résilients avec trois nœuds primaires sur des instances à la demande. Cette configuration s'applique pendant toute la durée de vie de votre cluster. [En savoir plus](#)

► Configuration de nœud - *facultatif*

Unité principale

Choisir un type d'instance EC2

m5.xlarge

4 vCore 16 GiB mémoire

EBS uniquement stockage

Prix à la demande : 0.224 USD par insta...

Prix Spot le plus bas : 0.078 USD (eu-west...

Actions ▼

► Configuration de nœud - *facultatif*

▼ Dimensionnement et mise en service du cluster - *requis* [Info](#)

Choisissez la manière dont Amazon EMR doit dimensionner votre cluster.

Choisir une option

☒ Définir manuellement la taille du cluster
Utilisez cette option si vous connaissez vos modèles de charge de travail à l'avance.

☐ Utiliser la mise à l'échelle gérée par EMR
Surveillez les principales métriques de charges de travail afin qu'EMR puisse optimiser la taille du cluster et l'utilisation des ressources.

☐ Utiliser un autoscaling personnalisé
Pour dimensionner de manière programmatique les unités principales et les nœuds de tâches, créez des politiques d'autoscaling personnalisées.

Configuration de mise en service

Définissez la taille de votre noyau et tâchegroupes d'instance. Amazon EMR tente de fournir cette capacité lorsque vous lancez votre cluster.

Nom	Type d'instance	Taille de l'instance(s)	Utiliser l'option d'achat Spot
Unité principale	m5.xlarge	2	☐
Tâche - 1	m5.xlarge	1	☐



Actions d'amorçage du cluster EMR

▼ Actions d'amorçage (1) [Info](#)

Utilisez les actions d'amorçage pour installer des logiciels ou personnaliser la configuration de votre instance.

[Supprimer](#)[Modifier](#)[Ajouter](#)

	Nom	Emplacement Amazon S3 ↗	Arguments
☐	InstallLibs	s3://p11-bucket-1742660397/bootstrap-emr.sh	-

Persistence des notebooks dans S3

▼ Paramètres du logiciel [Info](#)

Remplacez les configurations par défaut pour des applications spécifiques de votre cluster.

☒ Entrer la configuration

☐ Charger JSON à partir d'Amazon S3

1 ▼ []

2 ▼ {

3 "classification": "jupyter-s3-conf",

4 ▼ "properties": {

5 "s3.persistence.bucket": "p11-bucket-1742660397",

6 "s3.persistence.enabled": "true"

7 }


8 }

9 []

JSON Ln 9, Col 2 ⊕ : 0 ⚠ : 0

⚙

Transfert Learning avec MobileNetV2



Images brutes

Images non traitées
à partir du jeu de
données

Transfert learning

Utilisation du
modèle préentraîné
MobileNetV2

Vecteurs de caractéristiques

Extraction d'un vecteur de
dimension (1, 1, 1280)


Réduction de dimension

Préalable au
traitement PCA


Représentations optimisées

Vecteurs pertinents
prêts pour le
traitement distribué


Vue d'ensemble de la chaîne PySpark



Chargement et préparation des données



Extraction des caractéristiques avec MobileNetV2



Initialiser MobileNetV2



Diffuser le modèle



Appliquer pandas UDF



Transformer les images



Obtenir des vecteurs de caractéristiques

Réduction de dimension avec PCA





Sauvegarde et export des résultats

Vecteurs Compressés

Représente les données réduites en dimension et leurs métadonnées.

Sauvegarde S3

Au format Parquet, un format de fichier optimisé pour l'exportation et l'analyse.

Vérification des Données

Assure l'intégrité et la cohérence des données après exportation.


Accessibilité Cloud

Met l'accent sur l'accessibilité à distance et la scalabilité.


Démonstration d'exécution du script PySpark sur le Cloud



Retour critique sur la solution mise en œuvre



Conclusion



Avez-vous des questions?

